

Blackjack Game

Matěj Severýn

ČVUT–FIT

severmat@fit.cvut.cz

28. května 2025

1 Úvod

Cílem této práce je vytvořit počítačovou verzi karetní hry Blackjack s grafickým uživatelským rozhraním (GUI), která umožní hru více hráčům současně. Hra bude rozšířena o různé AI agenty, kteří budou využívat odlišné strategie hraní, jako je počítání karet, Q-learning a Deep Q-learning. Tato implementace umožní porovnat účinnost jednotlivých přístupů a zároveň vytvoří zábavné a interaktivní prostředí pro testování umělé inteligence ve hře Blackjack.

2 Funkce hry

Vyvinutá hra nabízí několik klíčových funkcí, které rozšiřují možnosti klasické hry a zvyšují uživatelský komfort:

- **Podpora více hráčů** – hra umožňuje zapojení více lidských i AI hráčů současně.
- **Grafické uživatelské rozhraní (GUI)** – vizuální rozhraní zobrazuje aktuální stav hry, karty, skóre a volby hráčů.
- **Možnost výběru ovládání hráče** – hráč může být ovládán buď člověkem, nebo různými typy AI agentů.
- **Uložení progresu hráčů** – herní statistiky a výsledky jednotlivých hráčů lze ukládat pro pozdější použití.

3 Metody a algoritmy

Pro řešení úlohy byly využity metody posilovaného učení, zejména hluboké neuronové sítě.

3.1 Počítání karet

Počítání karet je technika používaná k odhadu výhodnosti aktuální situace v karetní hře na základě již odehraných karet. V tomto projektu byl použit Hi-Lo systém, který přiřazuje kladné, záporné nebo nulové body jednotlivým hodnotám karet a na základě součtu určuje míru výhodnosti pro hráče.

Metoda byla postavena na principech z knihy od Edwarda O. Thorpa [2].

3.2 Q-learning


Q-learning je metoda posilovaného učení bez modelu prostředí, která se snaží naučit optimální politiku pomocí iterativní aktualizace hodnotové funkce Q . Agent se učí, jaká akce v daném stavu maximalizuje budoucí očekávanou odměnu [3]. Pro efektivní uložení a přístup k rozsáhlé Q -tabuli byla v tomto projektu využita databáze LMDB, která umožňuje rychlé čtení a zápis i při velkém množství stavů.

3.3 Deep Q-learning

Deep Q-learning rozšiřuje klasický Q-learning o využití hlubokých neuronových sítí pro aproximaci Q -funkce. Díky tomu lze pracovat i s velmi rozsáhlými stavovými prostory, které by jinak nebylo možné efektivně reprezentovat tabulkou [1]. V tomto projektu byla implementována architektura Dueling DQN s využitím noisy layers pro podporu průzkumu prostoru akcí bez nutnosti externího ϵ -greedy schématu.

4 Výsledky

Pro porovnání tří zvolených metod jsme použili jednoduchý systém odměn pro vyhodnocení úspěšnosti agenta. Po každé hře agent obdrží binární odměnu: 1, pokud získá alespoň 2000 žetonů (dvojnásobek počátečního rozpočtu), nebo 0 v případě bankrotu. Tento přístup umožňuje objektivně sledovat a porovnat efektivitu jednotlivých metod v průběhu her.



Obrázek 1: Srovnání metod podle odměny

Z grafu je patrné, že počítání karet dosahuje až 43 % úspěšnosti se stabilizací po 400 hrách. Deep Q-learning rychle roste a mezi 130. a 200. hrou mírně překonává počítání karet s maximem kolem 40 %. Klasický Q-learning dosahuje nejnižší úspěšnost kolem 16 % a stabilizuje se po 100 hrách.

5 Závěr

Projekt je navržen tak, aby umožnil ostatním uživatelům pokračovat v jeho rozvoji. Uživatelé mohou přidávat nové funkce, vylepšovat grafické uživatelské rozhraní, implementovat pokročilejší metody učení či rozšiřovat prvky herního prostředí.

Reference

- [1] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 2015. [online]. [visited on 2025-04-28].
- [2] Edward O. Thorp. *Beat the Dealer: A Winning Strategy for the Game of Twenty-One*. Random House, New York, 1962.
- [3] Christopher JCH Watkins and Peter Dayan. Q-learning. *Machine Learning*, 8:279–292, 1992. [online]. [visited on 2025-04-28].